

RELATÓRIO DE REVISÃO DA VERSÃO FINAL DO TC II

Eduardo Zanella Bento

Detecção Automática de Voz Sintética Utilizando Técnicas de Machine Learning

Etapa: revisão final para entrega e defesa

Data da revisão: 07/10/2026

1. Parecer geral

Foi realizada uma revisão detalhada da versão final do trabalho, considerando estrutura, fundamentação teórica, metodologia, execução experimental, resultados, discussão, figuras, tabelas, quadros, conclusão e referências. Também foram conferidos os resultados centrais contra os artefatos registrados no repositório do projeto.

De maneira geral, o trabalho está tecnicamente consistente, bem desenvolvido e com boa maturidade experimental. A estrutura metodológica está clara, os resultados estão adequadamente registrados e a seção de limitações é especialmente transparente. A conclusão principal - de que, dentro do protocolo experimental adotado, a CNN apresentou desempenho preditivo superior ao SVM e ao Random Forest, enquanto a análise de custo depende do regime de hardware - está sustentada pelos resultados.

Parecer: O trabalho está APROVÁVEL APÓS CORREÇÕES OBRIGATÓRIAS. Os experimentos centrais não precisam ser reabertos neste momento. As correções solicitadas são principalmente de precisão científica, formulação estatística, redação, referências e apresentação.

2. Resumo das correções prioritárias

Prioridade	Ponto	Ação
CRÍTICA	Referência BLUE et al. (2022)	Comprovar a fonte original ou remover/substituir todas as ocorrências.
CRÍTICA	Definição estatística de modelo competitivo	Corrigir a interpretação de IC95 contendo zero; isso não prova equivalência.
ALTA	Acurácia como eixo da pergunta de pesquisa	Substituir por desempenho preditivo quando estiver nomeando o eixo central.
ALTA	Padding 'idêntico em todos os áudios'	Corrigir: o valor do padding é zero; a quantidade varia entre os áudios.
ALTA	Atalho do silêncio 'removido'	Trocar por mitigado ou controlado.
ALTA	Windows 11 no texto x Windows 10 no artefato	Verificar e reconciliar com nota explicativa, se necessário.
ALTA	Afirmção de uso em tempo real	Qualificar: processamento faster-than-real-time após o trecho de 4 s estar disponível.
MÉDIA/ALTA	CNN e SVM 'empatam na prática'	Reformular como tempos da mesma ordem de grandeza, sem equivalência formal.
MÉDIA/ALTA	Justificativa da subamostra de 30 mil	Apresentar como orçamento experimental pré-fixado, não inviabilidade absoluta.
MÉDIA/ALTA	Quadros e tabelas multipágina	Aplicar continua/continuação e repetir cabeçalho quando necessário.

3. Correções obrigatórias

3.1 Referência BLUE et al. (2022)

Prioridade: CRÍTICA

A referência apresentada como "BLUE, A. et al. Deepfakes and Synthetic Media in the Financial Sector: Risks and Opportunities. Journal of Cybersecurity, v. 8, n. 1, 2022" precisa ser verificada. Ela é utilizada em diferentes partes do trabalho, inclusive na Introdução, Justificativa, Fundamentação, Trabalhos Relacionados e Quadro 1.

Ações esperadas:

- Localizar e apresentar a fonte original utilizada, preferencialmente com DOI, página oficial do periódico, PDF original ou outra forma confiável de identificação bibliográfica.
- Se a publicação não puder ser localizada e comprovada, retirar a referência da lista final e substituir todas as citações BLUE et al. (2022) por fontes reais que sustentem as afirmações feitas.
- Não substituir apenas o nome do autor. Cada afirmação deve ser novamente confrontada com a fonte que passará a sustentá-la.

3.2 Trocar 'acurácia' por 'desempenho preditivo' na pergunta central

Prioridade: ALTA

A pergunta de pesquisa foi formulada em termos de desempenho competitivo "em acurácia e viabilidade computacional". Entretanto, o próprio experimento mostra que a acurácia isolada não é um critério adequado para decidir a comparação, devido ao desbalanceamento aproximado de 9:1 entre spoof e bonafide. A decisão central foi sustentada principalmente por F1-macro e EER.

Ações esperadas:

- Alterar o eixo conceitual para 'desempenho preditivo e viabilidade computacional'.
- Manter acurácia como métrica reportada, mas não como o nome do eixo pelo qual a competitividade foi decidida.
- Revisar a terminologia no Resumo, Abstract, Introdução, pergunta de pesquisa, justificativa, Seção 5.9 e Conclusão.

3.3 Corrigir a definição estatística de 'competitivo'

Prioridade: CRÍTICA

O texto utiliza a ideia de que, se o intervalo de confiança da diferença entre modelos contivesse zero, os modelos poderiam ser considerados competitivos ou equivalentes. Essa interpretação precisa ser corrigida. Um intervalo contendo zero significa apenas que não foi possível demonstrar diferença estatisticamente distinguível. Isso não demonstra equivalência. Equivalência ou não inferioridade exigiria um desenho específico e uma margem previamente definida.

Ações esperadas:

- Reescrever a regra na Seção 3.8 e revisar a leitura correspondente na Seção 5.9.

- Usar formulação semelhante a: 'Caso o intervalo contivesse zero, não seria possível demonstrar diferença estatisticamente distinguível entre os modelos neste protocolo; isso, isoladamente, não constituiria prova formal de equivalência.'
- Manter a conclusão observada, pois os IC95 encontrados ficaram claramente afastados de zero.

3.4 Corrigir a afirmação sobre o padding

Prioridade: ALTA

Na discussão do pré-processamento aparece a afirmação de que "o padding é determinístico, idêntico em todos os áudios". Isso está incorreto. O valor utilizado para preenchimento é determinístico e igual a zero, mas a quantidade de padding varia entre os áudios de acordo com a duração de fala válida após o VAD.

Ações esperadas:

- Substituir por uma redação que diferencie o valor do padding da sua quantidade.
- Sugestão: 'O valor inserido no padding é determinístico (zero) e serve para igualar o formato das entradas; a quantidade de padding, entretanto, varia entre os áudios de acordo com a duração da fala válida remanescente.'

3.5 Trocar 'atalho do silêncio removido' por 'mitigado/controlado'

Prioridade: ALTA

Na conclusão, o atalho relacionado à duração do silêncio é descrito como "identificado e removido por desenho". A afirmação é forte demais diante das próprias evidências do trabalho. Ainda há correlação residual em mfcc1_std, efeito mensurável em ablação e possíveis influências do padding na Batch Normalization e nas posições de fronteira.

Ações esperadas:

- Substituir 'removido' por 'mitigado por desenho' ou 'explicitamente controlado no desenho experimental'.
- Não afirmar eliminação completa do efeito.

3.6 Reconciliar Windows 11 x Windows 10

Prioridade: ALTA

A Seção 3.10 informa Windows 11, enquanto o artefato experimental congelado no repositório registra o sistema como Windows 10. A divergência pode decorrer da forma como a biblioteca identifica versões do Windows, mas precisa ser explicada.

Ações esperadas:

- Verificar qual era efetivamente o sistema operacional da máquina utilizada.
- Se era Windows 11 e o coletor automático registrou Windows 10, inserir uma nota explicativa.
- Se era Windows 10, corrigir o texto.

3.7 Qualificar a afirmação sobre uso em tempo real

Prioridade: ALTA

O trabalho afirma que todos os arranjos ficaram abaixo de aproximadamente 17 ms por áudio e, portanto, não impediriam aplicação em tempo real. Entretanto, os modelos operam sobre trechos de 4,0 segundos. Se o trecho completo precisa ser recebido antes da classificação, a latência total percebida não é apenas o tempo de processamento.

Ações esperadas:

- Substituir a afirmação por uma formulação de processamento mais rápido que o tempo real após o segmento estar disponível.
- Sugestão: 'O custo computacional de processamento ficou muito abaixo da duração de 4,0 s do trecho analisado, indicando capacidade de processamento mais rápida que o tempo real após a disponibilização do segmento. A latência de aquisição e um cenário de inferência contínua em streaming não foram avaliados.'

3.8 Reformular 'CNN e SVM empatam na prática'

Prioridade: MÉDIA/ALTA

Os tempos ponta a ponta foram muito próximos - aproximadamente 4,58 ms para CNN/GPU e 4,92 ms para SVM/CPU - e a diferença observada ficou dentro da variação temporal registrada entre sessões. Isso sustenta uma interpretação de mesma ordem de grandeza, mas não um teste formal de equivalência.

Ações esperadas:

- Substituir 'empatam na prática' por uma formulação mais cautelosa.
- Sugestão: 'CNN em GPU e SVM apresentaram tempos ponta a ponta da mesma ordem de grandeza, e a diferença observada ficou dentro da variação temporal medida entre execuções, não permitindo sustentar uma ordenação estável entre os dois cenários.'

3.9 Reformular a justificativa da subamostra de 30.000

Prioridade: MÉDIA/ALTA

A subamostra de 30 mil foi definida considerando o custo do SVM-RBF. Essa motivação é aceitável, mas o texto não deve sugerir que o treino completo foi comprovadamente inviável, pois ele não chegou a ser executado com 103.723 exemplos. A busca em 30 mil também ficou abaixo do orçamento previsto.

Ações esperadas:

- Apresentar os 30 mil como orçamento experimental comum fixado a priori.
- Sugestão: 'A subamostra de 30.000 exemplos foi fixada a priori como orçamento experimental comum, considerando a escalabilidade do SVM com kernel RBF e a necessidade de manter o mesmo volume de treinamento no braço principal.'

4. Ajustes metodológicos e de redação

4.1 Expressão 'mesmo front-end'

Os dois ramos compartilham o mesmo pré-processamento e várias convenções acústicas, mas não exatamente o mesmo front-end: o ramo clássico usa FFT 512 e MFCC com DCT; a CNN usa FFT 1.024 e Log-Mel 128 x 251. Preferir 'convenções de front-end alinhadas' ou 'pré-processamento comum e representações construídas a partir de convenções acústicas alinhadas'.

4.2 Expressão 'mesmo treino'

Na conclusão, substituir 'o mesmo treino' por 'a mesma amostra final de treinamento no braço principal'. RF/SVM usam validação cruzada; a CNN usa 27k/3k para seleção e depois refit nos 30k.

4.3 Tacotron e WaveNet

Revisar o trecho que sugere que ambos realizam exatamente o mesmo fluxo de texto até a forma de onda. Distinguir modelos que produzem representações espectrais de modelos/vocoders que geram a forma de onda.

4.4 MFCC

Evitar formulações categóricas como 'MFCC isola a ressonância do trato vocal'. Preferir 'representa aspectos do envelope espectral associados às características do trato vocal'. Para coeficientes superiores, usar 'tendem a representar variações espectrais mais finas'.

4.5 Espectrograma e visão computacional

Evitar dizer que o problema simplesmente 'migra para a visão computacional'. Preferir: 'a representação tempo-frequência permite aplicar convoluções bidimensionais para explorar padrões locais do espectrograma'.

4.6 Alcance da revisão bibliográfica

Evitar generalizações como 'parte expressiva da literatura'. Com base no conjunto revisado, usar 'entre os trabalhos revisados nesta pesquisa...' para delimitar corretamente o alcance da afirmação.

4.7 Kernel RBF

Suavizar a afirmação de que o RBF 'contém o kernel linear como caso limite'. Preferir uma formulação do tipo: 'para valores muito baixos de gamma, o RBF pode aproximar um regime de decisão próximo ao linear sob determinadas condições'.

4.8 SoundFile/libsndfile

Se o texto generaliza a falha das versões 0.13/0.14, reformular como achado do ambiente experimental: 'Neste ambiente experimental, as versões 0.13 e 0.14 apresentaram falha determinística em...'

5. Figuras, tabelas e quadros

O conteúdo visual está, no geral, muito bom: as figuras são relevantes, os gráficos estão relacionados diretamente às análises e as tabelas registram adequadamente o protocolo e os resultados. Os principais ajustes necessários são de paginação, clareza de legenda e padronização.

Elemento	Avaliação	Correção/ação
----------	-----------	---------------

Figura 1 - Fluxograma experimental	Muito boa e didática.	Manter. Se desejar, simplificar a fonte longa de caminhos de arquivos.
Tabelas 1 e 2	Boas e úteis.	Na Tabela 2, usar continua/continuação se mantiver a quebra; usar '—' quando não houver ataque.
Quadro 1	Conteúdo útil, mas pior quebra visual do documento.	Mover inteiro para a página seguinte ou usar continuação com cabeçalho repetido. Resolver BLUE et al.
Quadros 2 e 3	Conteúdo muito bom.	Aplicar continuação adequada quando necessário; preservar o Quadro 3.
Tabela 3 - Arquitetura CNN	Muito boa e reproduzível.	Aplicar continuação formal entre páginas.
Figura 2 - Partição dos dados	Excelente.	Manter.
Figura 3 - Correlação antes/depois	Boa.	Adicionar nota explicando pontos abaixo/acima da diagonal.
Figura 4 - Curva de aprendizado RF	Boa.	Manter.
Figura 5 - Espectrogramas	Excelente.	Manter; opcionalmente ampliar títulos dos painéis.
Figura 6 - Grade da CNN	Útil, porém carregada.	Simplificar códigos na legenda e destacar a vencedora.
Figura 7 - Curvas da CNN	Boa.	Manter.
Figura 8 - ROC	Muito boa.	Manter.
Figura 9 - Matrizes de confusão	Excelente.	Manter.
Figura 10 - Validação x teste	Boa.	Manter.
Figura 11 - EER por ataque	Densa, porém legível.	Manter.
Figura 12 - Resultado por codec	Excelente.	Manter.
Figura 13 - Custo computacional	Muito boa.	Manter; preservar cautela na interpretação CNN/GPU x SVM.
Figura 14 - Importância de features	Muito boa.	Manter.
Tabelas 12 e 19	Conteúdo central.	Usar 'continua/continuação' e repetir cabeçalho.

6. Resultados e interpretação

Os resultados centrais devem ser preservados. Não foi identificada necessidade de refazer os experimentos principais. No teste, os valores finais apresentados são coerentes com os artefatos do repositório:

Modelo	F1-macro	EER	Interpretação
CNN	0,8883	0,0737	Melhor desempenho preditivo no protocolo.
SVM	0,7981	0,1411	Segundo melhor desempenho.
RF	0,7210	0,1946	Pior dos três no braço principal.

RF referência	0,7602	0,1629	Mede o efeito da subamostragem; não é concorrente direto.
---------------	--------	--------	---

A análise por classe deve continuar destacada, porque a diferença entre os modelos está fortemente associada à capacidade de reconhecer a classe bonafide, que é minoritária. A Tabela 10 e as matrizes de confusão são fundamentais para demonstrar por que a acurácia isolada não deve governar a comparação.

Também devem ser preservados: o bootstrap pareado, o braço de referência do RF, a análise por ataque e codec, a decomposição do custo computacional e a análise de importância de características.

7. Seção de limitações

A Seção 5.10 é uma das partes mais fortes do trabalho e deve ser preservada. Ela delimita corretamente o alcance das conclusões e evita extrapolações indevidas.

Manter explicitamente as seguintes limitações:

- partição aleatória por áudio, com ataques, codecs e locutores presentes nos diferentes subconjuntos;
- protocolo diferente do benchmark oficial do ASVspoof;
- ausência de leave-one-attack-out;
- uso de um único dataset;
- CNN treinada com uma única semente;
- combinação MFCC/FFT 512 no ramo clássico em regime numericamente menos favorável que a CNN;
- SVM não treinado no conjunto completo de 103.723 exemplos;
- efeitos residuais de padding e Batch Normalization na CNN;
- medição de custo em um único equipamento.

Essas limitações não invalidam o trabalho. Elas definem corretamente aquilo que pode e aquilo que não pode ser afirmado a partir dos resultados.

8. Conclusão - formulação recomendada

Sugestão: Dentro do protocolo experimental adotado, com 30.000 exemplos compartilhados no braço principal e partição aleatória por áudio, os modelos clássicos não apresentaram desempenho preditivo competitivo com a CNN. No conjunto de teste, a CNN apresentou F1-macro de 0,8883 e EER de 0,0737, contra 0,7981 e 0,1411 do SVM e 0,7210 e 0,1946 do RF, com diferenças estatisticamente distinguíveis pelo bootstrap pareado. Em custo computacional, a conclusão depende do hardware e do regime de utilização: em CPU, os modelos clássicos apresentaram menor custo ponta a ponta que a CNN; com GPU, CNN e SVM apresentaram tempos da mesma ordem de grandeza nas medições realizadas.

Na contribuição do trabalho, substituir a afirmação de que o atalho do silêncio foi 'removido' por uma formulação de 'mitigado' ou 'controlado', coerente com as limitações registradas.

9. Referências

Realizar uma revisão final de padronização e verificabilidade das referências.

Referência	Ação
BLUE et al. (2022)	Comprovar ou remover/substituir - obrigatório.

European Parliament (2025)	Completar elementos bibliográficos, endereço eletrônico e data de acesso, quando aplicável.
Kingma; Ba (2015)	Padronizar 'Disponível em' e 'Acesso em'.
Zhang et al. (2025)	Conferir e completar artigo/DOI e demais elementos disponíveis.
Müller et al. (2022)	Conferir DOI e padronização.
Van den Oord et al.	Conferir forma de entrada do sobrenome na referência.

No corpo do trabalho, manter o sistema autor-data. A referência bibliográfica completa deve permanecer somente na lista final de referências.

10. Checklist antes de reenviar a versão corrigida

1. BLUE et al. (2022) resolvido.
2. 'Acurácia' substituída por 'desempenho preditivo' quando estiver nomeando o eixo central.
3. Definição estatística de 'competitivo' corrigida.
4. Frase sobre padding corrigida.
5. 'Silêncio removido' substituído por 'mitigado/controlado'.
6. Windows 10/11 reconciliado.
7. Afirmação sobre 'tempo real' qualificada.
8. 'CNN e SVM empatam' reformulado.
9. Justificativa dos 30 mil revisada.
10. 'Mesmo front-end' e 'mesmo treino' revisados.
11. Quadros e tabelas multipágina corrigidos.
12. Figura 6 simplificada.
13. Referências revisadas e padronizadas.
14. Resumo e Abstract atualizados após as alterações.
15. Revisão final de ortografia, concordância e padronização de termos estrangeiros.

11. Parecer final da revisão

O trabalho encontra-se em bom nível técnico e metodológico e está próximo de uma versão adequada para defesa. Os resultados centrais não precisam ser refeitos e a estrutura experimental deve ser preservada.

Entretanto, os pontos classificados como críticos e de alta prioridade devem ser corrigidos antes da entrega definitiva, principalmente a referência BLUE et al. (2022), a definição estatística de competitividade, a terminologia acurácia/desempenho preditivo, as afirmações sobre padding e remoção do atalho de silêncio e a divergência no sistema operacional.

Orientação final: Após a aplicação dessas correções, a nova versão deve ser encaminhada para uma última conferência antes da entrega definitiva.